Τεχνική Νοημοσύνη - Εργασιά 2

Ονοματεπώνυμο	A.M
Ηλίας-Θεοφάνης Γραββάνης	3200248
Μάριος Γόρδιος	3180036

Στην εργασία υλοποιήθηκαν οι αλγόριθμοι Naive Bayes και ο ID3

Μέρος Α

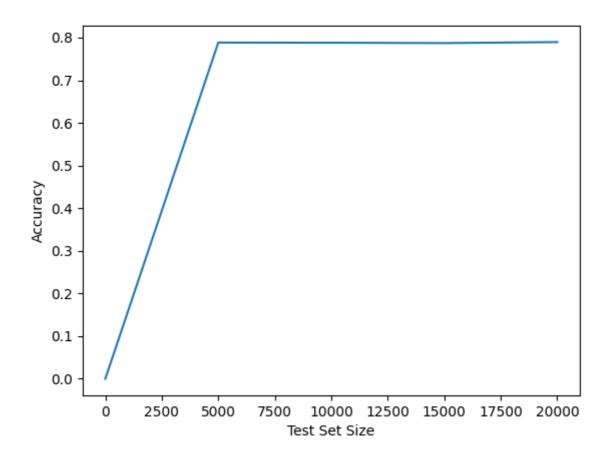
Αλγόριθμος Naive Bayes

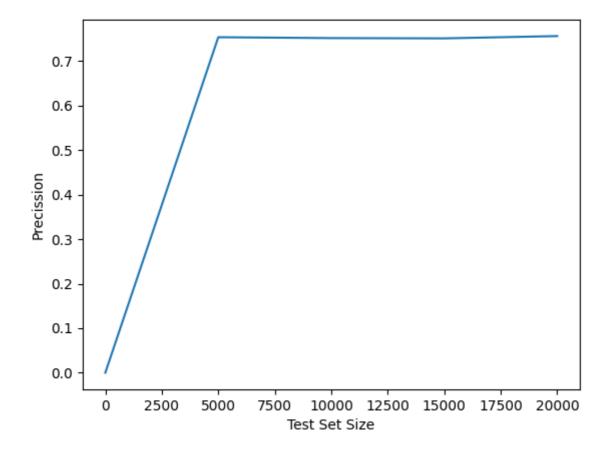
Στην υλοποίηση μας του αλγορίθμου Naive Bayes αρχικά παίρνουμε τις κριτικές των δεδομένων εκπαίδευσης για να δημιουργήσουμε ένα λεξικό, στο οποίο η κάθε λέξη έχει μοναδικό αναγνωριστικό (id) και συχνότητα, βάσει στην οποία θα υπολογιστούν οι πιθανότητες. Στη συνέχεια διαβάζουμε τα δοκιμαστικά δεδομένα (test data) και παίρνουμε ετικέτες για κάθε κριτική, χρησιμοποιώντας το λεξικό από τα δεδομένα εκπαίδευσης (training data) και τις πιθανότητες τους, χρησιμοποιώντας και τους προαναφερθέντες πίνακες συχνοτήτων. Για να υπολογίσουμε όλες τις πιθανότητες χρησιμοποιούμε την συνάρτηση log_sum η οποία διασφαλίζει ότι δεν θα προκύψει αριθμητικό overflow ή underflow. Χρησιμοποιείται και ένα "ALPHA" επίπεδο για να εξισορροπεί τις νέες λέξεις που εμφανίζονται. Η αξιολόγηση πραγματοποιείται μετρώντας την ορθότητα (accuracy), την ακρίβεια (precision), την ανάκληση (recall) για τα διαφορετικά επίπεδα του ALPHA (εμεις αξιοποιούμαι εδώ την παράμετρο με τιμή 0.01) και σχεδιάζοντας την καμπύλη ακριβείας (precision) και ανάκλησης (recall). Επιπλέον, εκτυπώνονται οι 20 πιο σημαντικές λέξεις της κάθε τάξης και υλοποιείται μια συνάρτηση που κάνει πρόβλεψη για κάθε κριτική.

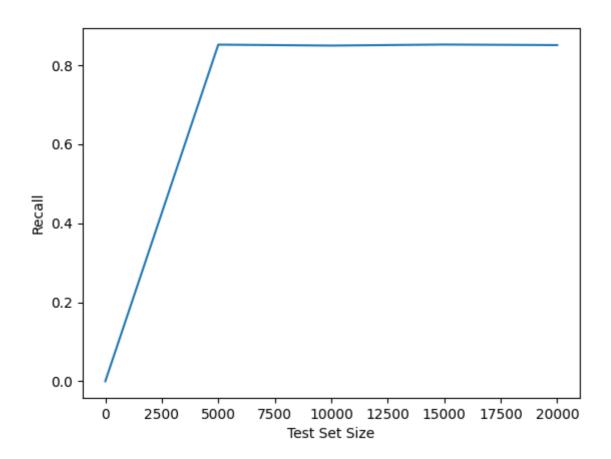
Πιο συγκεκριμένα, χρησιμοποιώντας τα IMDB.py και Vocabulary.py αρχεία παίρνουμε 2 πίνακες σε csr format. Ο πίνακας X είναι ένας μαθηματικός πίνακας που περιγράφει την συχνότητα του κάθε όρου των δεδομένων μας και το Y είναι ένας πίνακας με την ετικέτα (+1 ή -1) της κατηγορίας του κάθε αρχείου . Με τα παραπάνω δημιουργείται ένα λεξικό με το μοναδικά αναγνωριστικά (id) , τους πίνακες συχνοτήτων και τις κατηγορίες αρχείων. Η Train χρησιμοποιείται για τον υπολογισμό απαραίτητων παραμέτρων, όπως οι συνολικές κριτικές, συνολικές θετικές λέξεις, η συχνότητα κάθε λέξης της κατηγορίας, κ.λπ., οι οποίες θα χρησιμοποιηθούν αργότερα για τον υπολογισμό των πιθανοτήτων. Η συνάρτηση Assess χρησιμοποιείται για τη δοκιμή του αλγορίθμου. Καλείται το PredictLabel με τα test data για την αξιολόγηση των προβλέψεων . Η πιθανότητα P(C|W) (P(w δεδομένου c) υπολογίζεται χρησιμοποιώντας λογαριθμικό άθροισμα (έχουμε υλοποιήσει κατάλληλη συνάρτηση) των P(W|C) και P(C). Αυτά με τη σειρά τους έχουν υπολογισθεί από τη συνάρτηση Train. Με βάση το συνολικό θετικό score, το συνολικό αρνητικό score, και ένα δοσμένο όριο (threshold), εκχωρείται μια ετικέτα συγκρίνοντας την πιθανότητα με ένα όριο που έχει καθορισθεί από τον χρήστη. Έπειτα υπολογίζονται τα accuracy, precision, recall ανα αριθμο δεδομένων test ώστε να βλέπουμε την πρόοδο του αλγορίθμου για τις διάφορες μετρικές. Με την συνάρτηση predict_probability αποκτούμε τις ετικέτες που

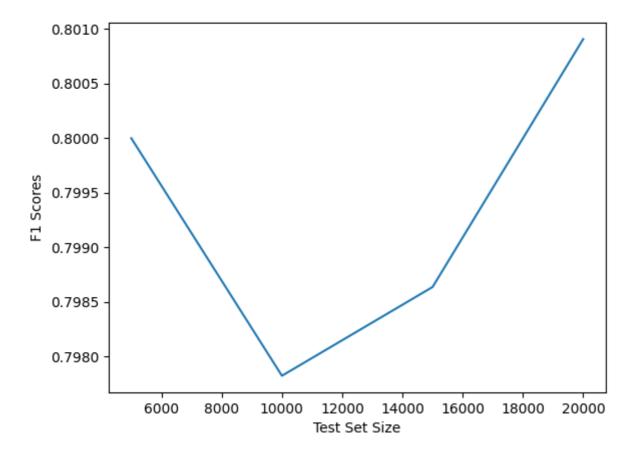
έχουν

προβλεφθεί, τις πραγματικές ετικέτες και 20 από τα αρχεία από των δεδομένων δοκιμής. Στη συνέχεια λαμβάνουμε τις 20 πιο συχνές θετικές ή αρνητικές λέξεις. Αυτό το κάνουμε υπολογίζοντας το Log odds (odds = ratio of something happening to something not happening) κάθε λέξης σε κάθε τάξη, και δημιουργώντας τη διαφορά αυτών των log odds για τον συνδυασμό κάθε λέξης και κατηγορίας. Υπολογίζουμε δηλαδή τη διαφορά της πιθανότητας P(w|c) των δύο κατηγοριών. Οι εξαιρετικά θετικές τιμές είναι οι λέξεις για τη θετική ετικέτα και οι εξαιρετικά αρνητικές για την αρνητική ετικέτα.









For the positive class:

Calculate the accuracy: 0.7918

Calculate the precision: 0.7607033092702452

Calculate the recall: 0.85144

Calculate the f1 score: 0.8035181759842966

For the negative class:

Calculate the accuracy: 0.7918

Calculate the precision: 0.8313198292306295

Calculate the recall: 0.73216

Calculate the f1 score: 0.7785954315368582

In Once again Nr. Cottons has dragged out a most for the longer than mostscape, Acide from the terrific on a recons sequences, of which there are very few 1 jost did not care about any of the characters. Next of an how goests in the closer, and Cottons, and Cottons

Για τον αλγόριθμο ID3 υλοποιήσαμε 4 κλάσεις. Αυτές είναι οι Node, DecisionTree, ID3, Utility. Για την εισαγωγή των δεδομένων στον αλγόριθμο ID3 χρησιμοποιήσαμε τις βιβλιοθήκες tensorflow και keras.

ID3: Εδώ έχουμε την κύρια λειτουργία του αλγορίθμου. Στη κλάση αυτή γίνεται η εισαγωγή των δεδομένων από το keras και σε αυτό το αρχείο τρέχει η main. Στην συνάρτηση id3_run παίρνει τα δεδομένα και παίρνει τις παρακάτω περιπτώσεις: να χρησιμοποιήσει το 20%, 40%, 60%, 80% και 100% των δεδομένων εκπαίδευσης. Με βάση αυτά τα δεδομένα φτιάχνει ένα δέντρο αναζήτησης για κάθε ποσοστό δεδομένων. Επίσης καλεί την Utility ώστε να βρει το best_attribute, το information gain και την εντροπία.

DecisionTree: Σε αυτή την κλάση δημιουργείται το δέντρο. Η συνάρτηση add_tree προσθέτει κάποιον κόμβο στο δέντρο ενώ η get_number_of_nodes επιστρέφει τον συνολικό αριθμό των κόμβων. Η κύρια λειτουργία της κλάσης γίνεται στην συνάρτηση classify στην οποία ελέγχει αν τα δεδομένα έχουν διαχωριστεί σωστά σε θετικές και αρνητικές κριτικές.

Node: Η κλάση αυτή ελέγχει αν ο κόμβος είναι φύλλο. Η συνάρτηση get_number επιστρέφει τον αριθμό του κόμβου. Η set_classification, εφόσον ο κόμβος είναι φύλλο, το βάζει σε κατηγορία, δηλαδή σε θετική ή αρνητική κριτική. Η get_classification επιστρέφει την κλάση του κόμβου. Η μέθοδος get_split_value επιστρέφει την τιμή βάσει της οποίας γίνεται και περαιτέρω διαχωρισμός του δέντρου. Η set_node_type ελέγχει αν έχουμε μόνο θετικές ή μόνο αρνητικές, και εφόσον είναι κάνει την μεταβλητή isLeaf True. Η get_majority_classification επιστρέφει αν έχουμε περισσότερες θετικές ή αρνητικές κριτικές.

Utility: Σε αυτή την κλάση, με την μέθοδο get_best_attribute και εφόσον έχουμε υπολογίσει την εντροπία(get_total_entropy) και το information gain(get_information_gain), βρίσκουμε το καλύτερο δεδομένο για να γίνει ο διαχωρισμός

Μέρος Β

Υλοποίθηκαν

Sklearn BernoulliNB

